

Desempenho de um modelo de Machine Learning

Métricas de avaliação:

Classificação

0) Matriz de confusão

		Previsto	
		Verdadeiro	Falso
Amostra	Verdadeiro	Verdadeiro Positivo (VP)	Falso Negativo (FN)
	Falso	Falso Positivo (FP)	Verdadeiro Negativo (VN)

1) Acurácia

- Indica o quanto o modelo acertou em classificar
- Razão entre os acertos e o total de amostras
- Taxa de acertos

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

Uso: Quando as classes estão balanceadas e o custo dos erros de classificação (falsos positivos e falsos negativos) é semelhante.

2) Precisão

- Indica a porcentagem de casos classificados como positivos que estão corretamente classificados

$$\text{Precisão} = \frac{VP}{VP + FP}$$

Uso: Quando o custo de falsos positivos é alto, ou seja, você quer minimizar o número de falsos positivos.

3) Recall – Sensibilidade

- Também chamado de taxa de verdadeiros positivos
- Porcentagem dos casos positivos da amostra que foram classificados como positivos pelo modelo
- Probabilidade de um positivo da amostra ser classificado como positivo no modelo

$$\text{Sensibilidade} = \frac{VP}{VP + FN}$$

Uso: Quando o custo de falsos negativos é alto, ou seja, é crucial capturar a maioria dos verdadeiros positivos.

4) Especificidade

- Também chamada taxa de verdadeiros negativos
- Porcentagem dos casos negativos da amostra que foram classificados como negativos pelo modelo
- Probabilidade de um negativo da amostra ser classificado como negativo no modelo

$$\text{Especificidade} = \frac{VN}{VN + FP}$$

Uso: Quando o foco é minimizar os falsos positivos e a classe negativa é de maior interesse.

5) F1 Score

- Combinação de precisão e sensibilidade em uma medida
- Média harmônica da precisão e da sensibilidade
- Valores maiores indicam melhor performance

$$\begin{aligned} \text{F1Score} &= 2 \times \frac{\text{Precisão} \times \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}} \\ &= \frac{2 \times VP}{2 \times VP + FP + FN} \end{aligned}$$

Uso: Quando há necessidade de um equilíbrio entre precisão e recall, especialmente com classes desbalanceadas.

6) Taxa de Falsos Positivos

- Porcentagem de verdadeiros da amostra que foram classificados incorretamente
- Pode ser encontrada por 1 – Especificidade
- Valores mais baixos são o ideal

$$\text{TFP} = \frac{FP}{VN + FP}$$

Uso: Quando é importante minimizar o número de falsos positivos em relação ao total de negativos.

7) Taxa de Falsos Negativos

- Porcentagem de falsos previstos que foram classificados incorretamente
- Valores mais baixos são o ideal

$$\text{TFN} = \frac{FN}{VP + FN}$$

Uso: Quando é crucial minimizar o número de falsos negativos em relação ao total de positivos.

Regressão

0) Erro residual

- Diferença entre valor observado e valor previsto

y = valor observado

\hat{y} = valor previsto


Erro Residual = $y - \hat{y}$

Ex: Gols numa partida

Observado: 1

Previsto: 3

Erro residual = -2



Amostra	Previsto	Erro (amostra - previsto)
5	10	-5
12	6	6
12	4	8
6	10	-4
11	6	5
8	12	-4
1	4	-3
5	8	-3

$$\text{Erro} = \frac{-5+6+8-4+5-4-3-3}{8} = 0 \text{ ???}$$

- Não é muito bom ser utilizado cru
- Muitas vezes não representa o erro real
- Por isso deve-se utilizar métricas mais complexas

1) MAE – Mean Absolute Error

- Média do erro residual na mesma magnitude da unidade em análise, como é um módulo não há valores negativos

$$\frac{\sum_{i=1}^n |y_j - \hat{y}_j|}{n}$$

n número de amostras

$y - \hat{y}$ Erro residual

$| \quad |$ módulo

\sum somatório dos termos

$\frac{1}{n}$ média

2) MSR – Mean Squared Error

- Medida para o próximo passo, dá mais peso a erros maiores

$$\frac{\sum_{i=1}^n (y_j - \hat{y}_j)^2}{n}$$

n número de amostras

$y - \hat{y}$ Erro residual

$(\quad)^2$ quadrado

\sum somatório dos termos

$\frac{1}{n}$ média

3) RMSE – Root Mean Squared Error

- Desvio padrão dos erros residuais
- Na mesma magnitude da amostra penaliza grandes erros

$$\sqrt{\frac{\sum_{i=1}^n (y_j - \hat{y}_j)^2}{n}}$$

n número de amostras

$y - \hat{y}$ Erro residual

$(\quad)^2$ quadrado

\sum somatório dos termos

$\frac{1}{n}$ média

$\sqrt{\quad}$ raiz quadrada

4) R² – R squared

- Também chamado de coeficiente de determinação
- Porcentagem da variância do modelo
- Mostra o quanto as variáveis independentes explicam a variável dependente

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_j - \hat{y}_j)^2}{\sum_{i=1}^n (y_j - \bar{y}_j)^2}$$